

Inteligentne Systemy Wspomagania decyzji

Wprowadzenie

mgr inż. Andrii Shekhoverstov

Uniwersytet WSB Merito

30 września 2025

Spis treści

1 Wprowadzenie i historia ISWD

- Geneza i rozwój
- Poddziedziny ISWD

2 Wprowadzenie do MCDA

- Problem decyzyjny

3 Metoda TOPSIS

- Idea i kroki algorytmu

4 Podsumowanie

Definicje ISWD

System wspomagania decyzji (Decision Support System, DSS)

System komputerowy, który wspiera decydenta w procesie podejmowania decyzji, łącząc dane, modele analityczne i interfejs użytkownika.

Inteligentny system wspomagania decyzji (ISWD)

Rozszerzenie DSS o elementy sztucznej inteligencji i metod zaawansowanej analizy, umożliwiające:

- modelowanie problemów złożonych i wielokryterialnych,
- wykorzystanie wiedzy eksperckiej i heurystyk,
- adaptację i uczenie się na podstawie danych.

Pytanie otwierające

Dlaczego komputery wspomagają decyzje, a nie decydują za nas?

- Decyzje często mają charakter wielokryterialny,
- Powinny uwzględniać preferencje i wiedzę ekspercką,
- Człowiek pozostaje odpowiedzialny za ostateczny wybór.

RODO (GDPR) – Artykuł 22

- Prawo osoby do **niepodlegania decyzji opartej wyłącznie na automatycznym przetwarzaniu**, jeśli decyzja wywołuje skutki prawne lub istotnie na nią wpływa.
- Dopuszczalne wyjątki:
 - zgoda osoby,
 - konieczność wykonania umowy,
 - szczególne przepisy prawa UE/krajowego.
- Wymagane: **interwencja człowieka**, prawo odwołania, transparentność.

AI Act (Akt o sztucznej inteligencji UE, 2024/2025)

- Zakazane praktyki AI o **nieakceptowalnym ryzyku**, m.in.:
 - manipulacja zachowaniem w sposób ukryty/oszukańczy,
 - wykorzystywanie słabości osób (np. wiek, niepełnosprawność),
 - systemy „social scoringu”,
 - przewidywanie przestępcości na podstawie cech biometrycznych.
- Automatyczne decyzje są dopuszczalne, jeśli istnieją odpowiednie gwarancje.

Historia badań operacyjnych (Operations Research)

- Dziedzina badań operacyjnych rozwinęła się w czasie **II wojny światowej**.
- Ówczesna definicja:
„Naukowa metoda dostarczania działom wykonawczym podstaw ilościowych do podejmowania decyzji dotyczących operacji znajdujących się pod ich kontrolą”.
- Około 1000 osób w UK było zaangażowane w badania operacyjne w trakcie II wojny światowej.

Współczesna definicja (INFORMS)

Operations Research to dziedzina stosująca zaawansowane metody analityczne, aby wspierać proces podejmowania lepszych decyzji.

Lata 50.–60.: początki OR i programowania liniowego

Rozwój badań operacyjnych po II wojnie światowej – zastosowania cywilne.

- 1947: opracowanie **metody simpleks** przez George'a Dantziga – przełom w rozwiązywaniu problemów optymalizacyjnych.
- Lata 50.: pierwsze zastosowania OR w przemyśle, telekomunikacji i transporcie.
- Rozwój **programowania liniowego** i jego zastosowania do:
 - problemów transportowych,
 - alokacji zasobów,
 - planowania produkcji.
- Lata 60.: pierwsze komercyjne oprogramowanie do rozwiązywania LP (np. IBM MPS).

Lata 70.: Decision Support Systems (DSS)

- Pojęcie Decision Support Systems (DSS) wprowadzone w latach 70.
- Kluczowe cechy DSS:
 - interaktywność z użytkownikiem,
 - integracja danych z różnych źródeł,
 - wykorzystanie modeli analitycznych i statystycznych,
 - wspomaganie decyzji w warunkach niepewności.
- Typowe zastosowania DSS w latach 70.:
 - planowanie produkcji i zasobów,
 - zarządzanie finansami i budżetowanie,
 - wspomaganie decyzji w logistyce i transporcie.

Lata 80.–90.: Systemy ekspertowe

- Rozwój systemów ekspertowych (**Expert Systems**) – systemów wspomagających decyzje w oparciu o wiedzę ekspercką.
- Kluczowe cechy systemów ekspertowych:
 - baza wiedzy zawierająca fakty i reguły decyzyjne,
 - mechanizm wnioskowania (inference engine) do dedukcji i rozwiązywania problemów,
 - interaktywny interfejs dla użytkownika.
- Typowe zastosowania:
 - diagnostyka medyczna (np. system MYCIN),
 - doradztwo techniczne i inżynierskie,
 - planowanie i harmonogramowanie w przemyśle.

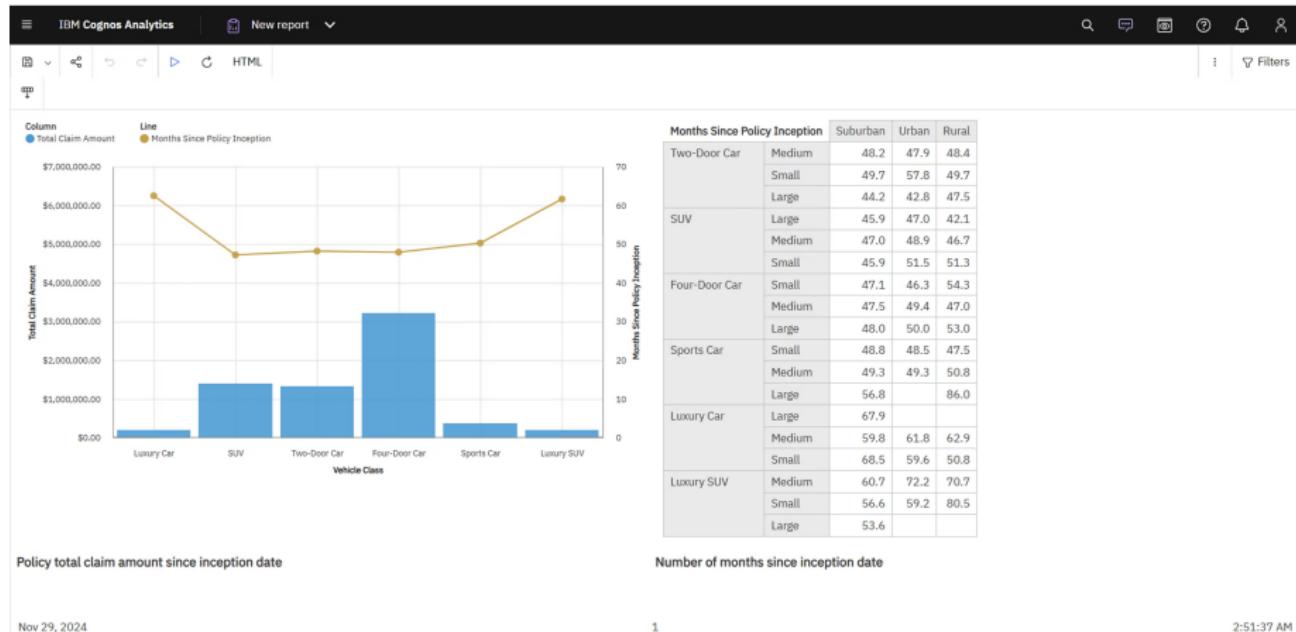
Po 2000 r.: Integracja DSS z AI, Big Data i IoT

- Ewolucja systemów wspomagania decyzji w kierunku **inteligentnych systemów wspomagania decyzji (ISWD)**.
- Kluczowe elementy integracji:
 - **Sztuczna inteligencja (AI)** – uczenie maszynowe, sieci neuronowe, systemy rekomendacyjne.
 - **Big Data** – analiza ogromnych zbiorów danych dla wsparcia decyzji w czasie rzeczywistym.
 - **Internet rzeczy (IoT)** – pozyskiwanie danych z sensorów i urządzeń w czasie rzeczywistym.
- Przykładowe zastosowania:
 - inteligentne zarządzanie produkcją i logistiką,
 - systemy rekomendacyjne w e-commerce i usługach,
 - analiza ryzyka i predykcja w finansach i energetyce.
- Systemy po 2000 r. łączą **modele matematyczne, wiedzę ekspercką i AI**, umożliwiając bardziej zaawansowane wspomaganie decyzji.

MYCIN (lata 70.-80.)

```
> (mycin)
----- PATIENT-1 -----
Patient's name: Sylvia Fischer
Sex: female
Age: 27
----- CULTURE-1 -----
From what site was the specimen for CULTURE-1 taken? blood
How many days ago was this culture (CULTURE-1) obtained? 3
----- ORGANISM-1 -----
Enter the identity (genus) of ORGANISM-1: unknown
The gram stain of ORGANISM-1: ?
A GRAM must be of type (MEMBER ACID-FAST POS NEG)
The gram stain of ORGANISM-1: neg
```

IBM Cognos Analytics

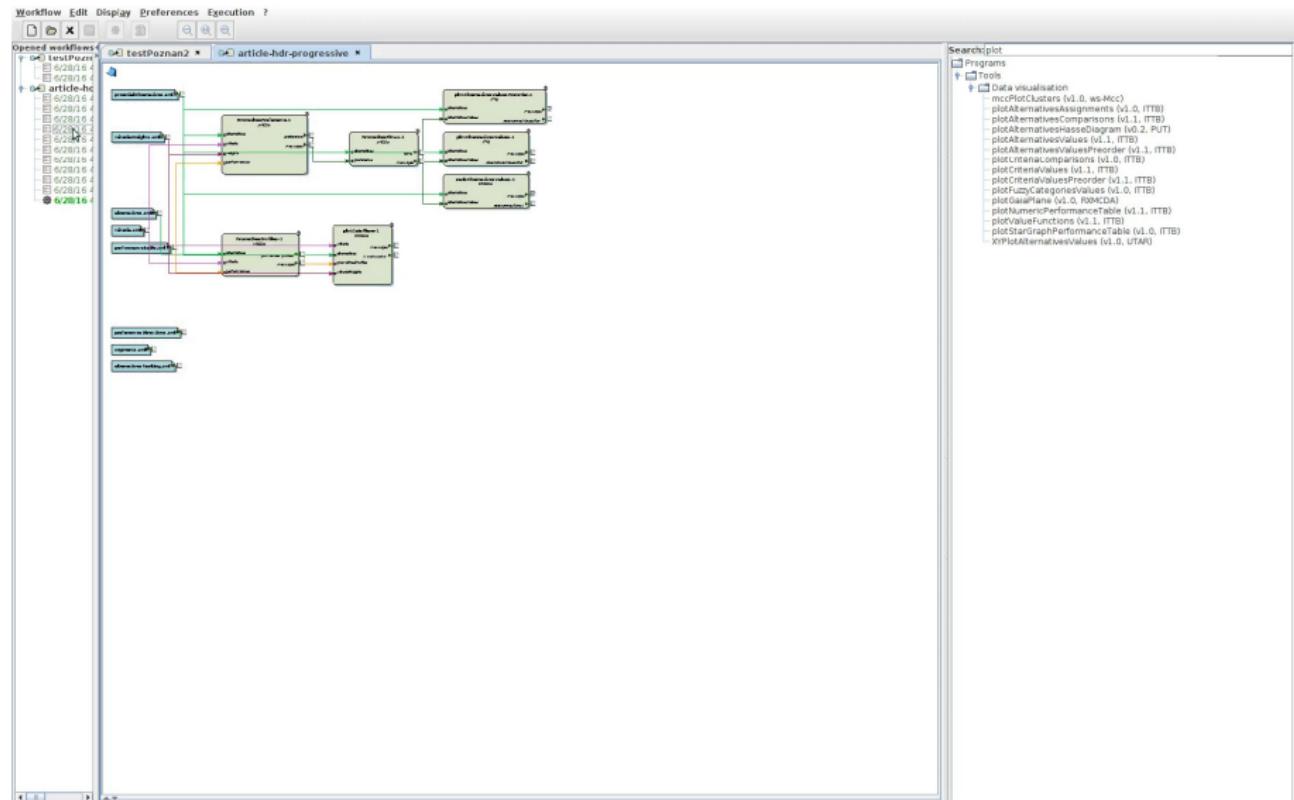


Nov 29, 2024

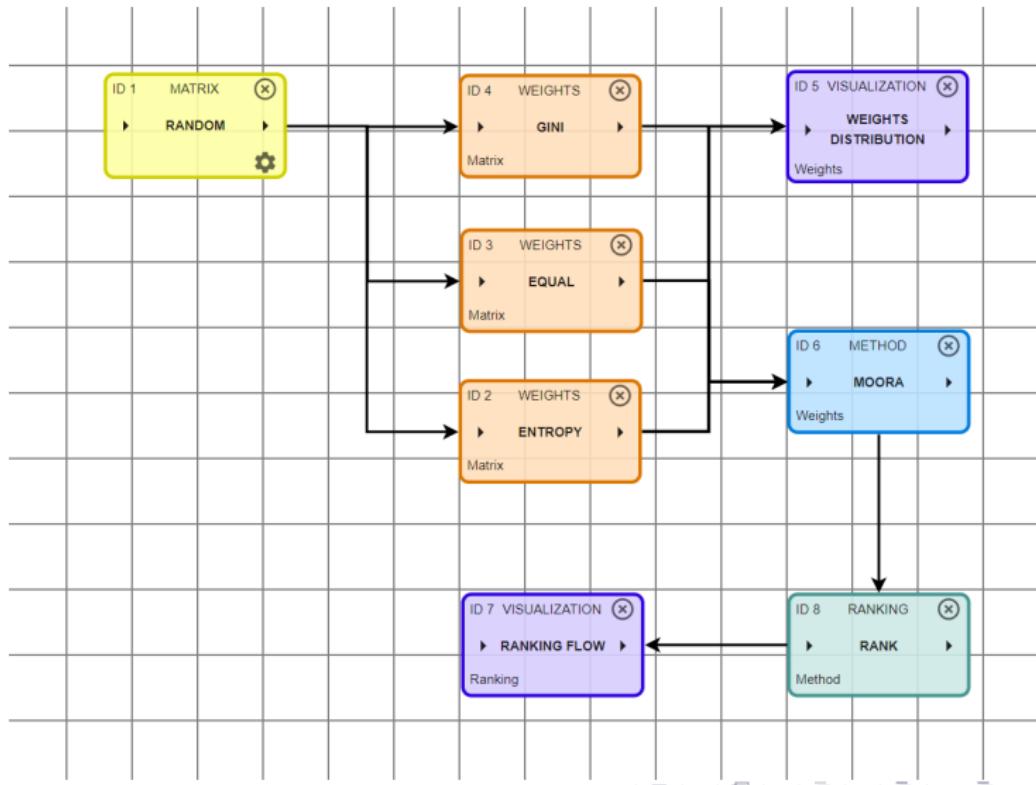
1

2:51:37 AM

DIVIZ



Make-Decision.it



Poddziedziny ISWD

- **Operations Research (OR)** – modele matematyczne i optymalizacja
 - Planowanie produkcji i logistyki, harmonogramowanie
- **MCDA – analiza wielokryterialna**
 - Wybór najlepszej alternatywy przy wielu kryteriach
- **Systemy ekspertowe** – reguły i baza wiedzy
 - Dedukcja i wnioskowanie na podstawie wiedzy eksperckiej
- **Systemy rekomendacyjne** – personalizacja decyzji
 - Analiza preferencji użytkownika, wsparcie decyzji zakupowych
- **Symulacje i analizy predykcyjne**
 - Modelowanie scenariuszy „co jeśli”: predykcja popytu, ryzyka
- **Decision Support Systems (DSS)** – systemy wspomagania decyzji
 - Łączą dane, modele analityczne i interfejs dla decydenta

Przykłady zastosowań ISWD 1

■ **Medycyna** – wspomaganie diagnozy i leczenia

- Systemy ekspertowe do diagnostyki chorób
- Shortliffe, E. H. (1977, October). Mycin: A knowledge-based computer program applied to infectious diseases. In Proceedings of the Annual Symposium on Computer Application in Medical Care (p. 66).

■ **Logistyka** – planowanie tras i alokacja zasobów

- Optymalizacja transportu, dostaw i magazynowania
- Vigo, D. (2004). The vehicle routing problem: Algorithms and applications. In Proceedings of the 9th International Conference on Operational Research (pp. 4-5). University of Osijek.

■ **Energetyka** – dobór technologii i analiza ryzyka

- Optymalizacja sieci energetycznych, predykcja zużycia
- Verwiebe, P. A., Seim, S., Burges, S., Schulz, L., & Müller-Kirchenbauer, J. (2021). Modeling energy demand—a systematic literature review. *Energies*, 14(23), 7859.

Przykłady zastosowań ISWD 2

■ Finanse – wspomaganie decyzji inwestycyjnych

- Ocena ryzyka kredytowego i portfela inwestycyjnego
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The journal of finance*, 23(4), 589-609.

■ Przemysł i produkcja – optymalizacja procesów

- Harmonogramowanie produkcji, zarządzanie zasobami
- Pinedo, M., & Hadavi, K. (1992). Scheduling: theory, algorithms and systems development. In *Operations research proceedings 1991: Papers of the 20th annual meeting/vorträge der 20. Jahrestagung* (pp. 35-42). Berlin, Heidelberg: Springer Berlin Heidelberg.

■ Administracja publiczna – planowanie i polityka

- Analiza danych demograficznych i ekonomicznych
- Wspomaganie decyzji strategicznych i kryzysowych
- Van Horne, J. C., & Wachowicz, J. M. (2005). *Fundamentals of financial management*. Pearson education.

Definicja MCDA (Analiza Wielokryterialna)

MCDA – Multiple Criteria Decision Analysis

MCDA to zbiór metod i technik wspomagających podejmowanie decyzji w sytuacjach, gdy istnieje wiele, często sprzecznych kryteriów oceny alternatyw.

- Umożliwia ocenę i ranking alternatyw w oparciu o wiele kryteriów jednocześnie.
- Wykorzystuje macierze decyzyjne, wagi kryteriów i oceny eksperckie.
- Przykładowe metody MCDA:
 - TOPSIS (Technique for Order Preference by Similarity to Ideal Solution)
 - AHP (Analytic Hierarchy Process)
 - ELECTRE (ELimination Et Choix Traduisant la REalité)
 - PROMETHEE (Preference Ranking Organization Method for Enrichment Evaluations)

Problem decyzyjny 1

Alternatywy (A_1, A_2, \dots)

Alternatywy to różne możliwe warianty działań lub rozwiązań, spośród których decydent musi dokonać wyboru.

- Wybór dostawcy – DPD, InPost, DHL,
- Wybór lokalizacji fabryki – Szczecin, Poznań, Wrocław.

Problem decyzyjny 2

Kryteria (C_1, C_2, \dots)

Kryteria to miary lub cechy, według których ocenia się alternatywy. Mogą być ilościowe lub jakościowe.

- Wybór sklepu internetowego - Cena produktu, czas dostawy,
- Wybór dostawcy - Jakość obsługi klienta, poziom emisji CO_2 .

Problem decyzyjny 3

Typy kryteriów

Typy kryteriów określają kierunek pożądanej wartości: maksymalizacyjne - zysk (im więcej, tym lepiej) lub minimalizacyjne - koszt (im mniej, tym lepiej). Czasami też cel (target) - najlepsza wartość jest najbliżej docelowej.

- Zysk – zysk firmy, liczba sprzedanych produktów,
- Koszt – koszt inwestycji, czas realizacji projektu,
- Cel (target) - temperatura w procesie chemicznym.

Problem decyzyjny 4

Wagi kryteriów

Wagi kryteriów to liczby przypisane poszczególnym kryteriom, które odzwierciedlają ich względne znaczenie dla decydenta w procesie wyboru najlepszej alternatywy. Wagi pozwalają uwzględnić priorytety i preferencje decydenta w analizie wielokryterialnej. Większość metod zakłada, że

- Przykład: Wybór dostawcy
 - Cena – waga 0.4
 - Jakość – waga 0.35
 - Termin dostawy – waga 0.25

Problem decyzyjny 5

Decydent

Decydent to osoba lub grupa osób odpowiedzialna za wybór najlepszej alternatywy, kierująca się swoimi preferencjami i wagami przypisanymi kryteriom.

- Menedżer projektu, który preferuje krótszy czas realizacji nad niższym kosztem,
- Inwestor, który bardziej ceni bezpieczeństwo inwestycji niż maksymalny zysk,
- Student informatyki, szukający laptopa do studiów i gier, w dobrej cenie.

Przykładowy problem decyzyjny

Kryteria i wagi

| C_j | Nazwa | Jednostki | w_j | Typ |
|-------|----------|-----------|-------|-----|
| C_1 | Przebieg | k km | 0.33 | Min |
| C_2 | Cena | k PLN | 0.56 | Min |
| C_3 | Rok | Rok | 0.11 | Max |

Alternatywy

| A_i | C_1 | C_2 | C_3 |
|-------|-------|-------|-------|
| A_1 | 94.0 | 69.9 | 2017 |
| A_2 | 297.0 | 42.0 | 2013 |
| A_3 | 205.0 | 68.9 | 2015 |
| A_4 | 360.0 | 36.9 | 2014 |
| A_5 | 86.0 | 59.9 | 2017 |
| A_6 | 79.6 | 63.8 | 2017 |
| A_7 | 113.0 | 56.9 | 2015 |
| A_8 | 171.0 | 58.0 | 2016 |

Ocena ekspercka

Motywacje

W wielu decyzjach brakuje danych liczbowych lub obiektywnych miar jakości alternatyw. Decydent musi oprzeć się na swojej wiedzy, doświadczeniu i subiektywnej ocenie.

Rozwiązanie

Użycie standaryzowanych skali ocen, np. skala Likerta (1–5 lub 1–7), aby zapewnić porównywalność.

Przykład oceny jakości dostawy

- Kryterium: Terminowość dostaw
- Skala Likerta 1–5: 1 – bardzo słaba, 5 – doskonała
- Ekspert ocenia dostawcę A na 4, dostawcę B na 2

Normalizacja danych w MCDA

Normalizacja

Normalizacja to proces przekształcania wartości kryteriów do wspólnej skali, aby umożliwić ich porównanie i agregację w analizie wielokryterialnej.

- Kryteria mogą mieć różne jednostki miary (np. km, PLN, lata) – bez normalizacji nie da się ich bezpośrednio porównać.
- Kryteria mogą mieć różne zakresy wartości – normalizacja zapobiega nadmiernemu wpływowi kryteriów o dużych wartościach liczbowych.
- Pozwala uwzględnić wagi kryteriów i preferencje decydenta w sposób spójny.
- Umożliwia stosowanie metod MCDA, które wymagają porównywalnych wartości (np. TOPSIS, ELECTRE, PROMETHEE).

Rodzaje normalizacji 1: Metoda minimum-maksimum

Min-max

Normalizacja oparta na wartościach najmniejszych i największych w zbiorze.

- Dla kryteriów typu „profit”: wartości rosną proporcjonalnie do odległości od minimum.
- Dla kryteriów typu „cost”: wartości maleją proporcjonalnie do odległości od maksimum.

$$r_{ij} = \frac{x_{ij} - \min_j(x_{ij})}{\max_j(x_{ij}) - \min_j(x_{ij})} \quad (\text{profit}) \quad (1)$$

$$r_{ij} = \frac{\max_j(x_{ij}) - x_{ij}}{\max_j(x_{ij}) - \min_j(x_{ij})} \quad (\text{cost}) \quad (2)$$

Rodzaje normalizacji 2: Metoda maksimum

Max

Normalizacja oparta tylko na wartości największej w zbiorze.

- Dla „profit”: wartości są dzielone przez maksimum.
- Dla „cost”: wartości są odejmowane od 1 po podzieleniu przez maksimum.

$$r_{ij} = \frac{x_{ij}}{\max_j(x_{ij})} \quad (\text{profit}) \quad (3)$$

$$r_{ij} = 1 - \frac{x_{ij}}{\max_j(x_{ij})} \quad (\text{cost}) \quad (4)$$

Rodzaje normalizacji 3: Metoda sumy

Sum

Normalizacja oparta na sumie wszystkich wartości w zbiorze.

- Dla „profit”: każda wartość dzielona przez sumę wartości.
- Dla „cost”: stosuje się odwrotność wartości, a następnie dzieli przez sumę odwrotności.

$$r_{ij} = \frac{x_{ij}}{\sum_{i=1}^m x_{ij}} \quad (\text{profit}) \quad (5)$$

$$r_{ij} = \frac{\frac{1}{x_{ij}}}{\sum_{i=1}^m \frac{1}{x_{ij}}} \quad (\text{cost}) \quad (6)$$

Rodzaje normalizacji 4: Metoda wektorowa

Vector

Normalizacja oparta na długości wektora (pierwiastek sumy kwadratów wartości).

- Dla „profit”: wartości dzielone przez pierwiastek sumy kwadratów.
- Dla „cost”: wartości odejmowane od 1 po tej normalizacji.

$$r_{ij} = \frac{x_{ij}}{\sqrt{\sum_{i=1}^m x_{ij}^2}} \quad (\text{profit}) \quad (7)$$

$$r_{ij} = 1 - \frac{x_{ij}}{\sqrt{\sum_{i=1}^m x_{ij}^2}} \quad (\text{cost}) \quad (8)$$

Rodzaje normalizacji 5: Metoda logarytmiczna

Log

Normalizacja oparta na logarytmie naturalnym. Wartości muszą być dodatnie.

- Dla „profit”: logarytm wartości dzielony przez logarytm iloczynu wszystkich wartości.
- Dla „cost”: logarytm wartości w odwroconej proporcji, przeskalowany przez liczbę alternatyw.

$$r_{ij} = \frac{\ln(x_{ij})}{\ln(\prod_{i=1}^m x_{ij})} \quad (\text{profit}) \quad (9)$$

$$r_{ij} = \frac{1 - \frac{\ln(x_{ij})}{\ln(\prod_{i=1}^m x_{ij})}}{m - 1} \quad (\text{cost}) \quad (10)$$

Idea metody TOPSIS

Definicja i idea

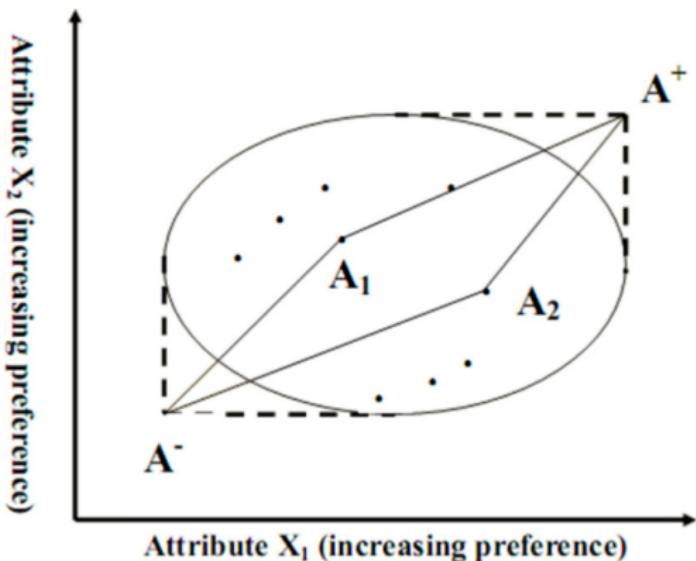
TOPSIS (Technique for Order Preference by Similarity to Ideal Solution) to metoda analizy wielokryterialnej, która ocenia alternatywy na podstawie odległości od rozwiązania idealnego i anty-idealnego.

- Najlepsza alternatywa jest najbliżej **rozwiązania idealnego** – maksymalnych wartości kryteriów korzystnych i minimalnych wartości kryteriów niekorzystnych.
- Jednocześnie jest najdalej od **rozwiązania anty-idealnego** – minimalnych wartości kryteriów korzystnych i maksymalnych wartości kryteriów niekorzystnych.

Twórcy metody

Hwang, C. L. (1981). Multiple attributes decision making. Methods and applications.

Schemat działania metody TOPSIS



TOPSIS: Krok 1 – Normalizacja macierzy decyzyjnej

Obliczamy znormalizowaną macierz decyzyjną r_{ij} , aby wartości wszystkich kryteriów były porównywalne. Używamy normalizacji min-max, która sprawdza się lepiej niż klasyczna normalizacja wektorowa. Można użyć innej metody normalizacji.

$$r_{ij} = \frac{x_{ij} - \min_j(x_{ij})}{\max_j(x_{ij}) - \min_j(x_{ij})} \quad (\text{kryteria profit}) \quad (11)$$

$$r_{ij} = \frac{\max_j(x_{ij}) - x_{ij}}{\max_j(x_{ij}) - \min_j(x_{ij})} \quad (\text{kryteria cost}) \quad (12)$$

TOPSIS: Krok 2 – Macierz ważona znormalizowana

Każda wartość znormalizowana jest mnożona przez wagę przypisaną kryterium, aby uwzględnić preferencje decydenta.

$$v_{ij} = w_j r_{ij} \quad (13)$$

TOPSIS: Krok 3 – Wyznaczenie PIS i NIS

Obliczamy wektory:

- PIS (Positive Ideal Solution) – maksymalne wartości każdego kryterium.
- NIS (Negative Ideal Solution) – minimalne wartości każdego kryterium.

Nie trzeba rozdzielać kryteriów na profit i cost, ponieważ normalizacja już uwzględnia kierunek kryteriów.

$$v_j^+ = \max_i(v_{ij}) \quad (14)$$

$$v_j^- = \min_i(v_{ij}) \quad (15)$$

TOPSIS: Krok 4 – Obliczenie odległości od PIS i NIS

Dla każdej alternatywy obliczamy odległość euklidesową od PIS i NIS.

$$D_i^+ = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^+)^2} \quad (16)$$

$$D_i^- = \sqrt{\sum_{j=1}^n (v_{ij} - v_j^-)^2} \quad (17)$$

TOPSIS: Krok 5 – Wyznaczenie oceny alternatywy

Obliczamy wskaźnik bliskości do rozwiązania idealnego dla każdej alternatywy. Wartość C_i mieści się w przedziale $[0,1]$, im bliżej 1, tym lepsza alternatywa.

$$C_i = \frac{D_i^-}{D_i^- + D_i^+} \quad (18)$$

Przykład zastosowania TOPSIS 1

Kryteria i wagi

| C_j | Nazwa | Jednostki | w_j | Typ |
|-------|----------|-----------|-------|-----|
| C_1 | Przebieg | k km | 0.33 | Min |
| C_2 | Cena | k PLN | 0.56 | Min |
| C_3 | Rok | Rok | 0.11 | Max |

Alternatywy

| A_i | C_1 | C_2 | C_3 |
|-------|-------|-------|-------|
| A_1 | 94.0 | 69.9 | 2017 |
| A_2 | 297.0 | 42.0 | 2013 |
| A_3 | 205.0 | 68.9 | 2015 |
| A_4 | 360.0 | 36.9 | 2014 |
| A_5 | 86.0 | 59.9 | 2017 |
| A_6 | 79.6 | 63.8 | 2017 |
| A_7 | 113.0 | 56.9 | 2015 |
| A_8 | 171.0 | 58.0 | 2016 |

Przykład zastosowania TOPSIS 2

Normalized decision matrix (r_{ij})

| A_i | C_1 | C_2 | C_3 |
|-------|--------|--------|--------|
| A_1 | 0.9486 | 0.0000 | 1.0000 |
| A_2 | 0.2247 | 0.8455 | 0.0000 |
| A_3 | 0.5528 | 0.0303 | 0.5000 |
| A_4 | 0.0000 | 1.0000 | 0.2500 |
| A_5 | 0.9772 | 0.3030 | 1.0000 |
| A_6 | 1.0000 | 0.1848 | 1.0000 |
| A_7 | 0.8809 | 0.3939 | 0.5000 |
| A_8 | 0.6740 | 0.3606 | 0.7500 |

Weighted norm. dec. matrix (v_{ij})

| A_i | C_1 | C_2 | C_3 |
|---------|--------|--------|--------|
| A_1 | 0.3131 | 0.0000 | 0.1100 |
| A_2 | 0.0741 | 0.4735 | 0.0000 |
| A_3 | 0.1824 | 0.0170 | 0.0550 |
| A_4 | 0.0000 | 0.5600 | 0.0275 |
| A_5 | 0.3225 | 0.1697 | 0.1100 |
| A_6 | 0.3300 | 0.1035 | 0.1100 |
| A_7 | 0.2907 | 0.2206 | 0.0550 |
| A_8 | 0.2224 | 0.2019 | 0.0825 |
| v_j^- | 0.0000 | 0.0000 | 0.0000 |
| v_j^+ | 0.3300 | 0.5600 | 0.1100 |

Przykład zastosowania TOPSIS 3

Ostatnie kroki i wyniki obliczeń

| A_i | D_i^- | D_i^+ | C_i | R_i |
|-------|---------|---------|--------|-------|
| A_1 | 0.3318 | 0.5603 | 0.3720 | 7 |
| A_2 | 0.4792 | 0.2916 | 0.6217 | 2 |
| A_3 | 0.1913 | 0.5654 | 0.2528 | 8 |
| A_4 | 0.5607 | 0.3402 | 0.6224 | 1 |
| A_5 | 0.3806 | 0.3904 | 0.4937 | 4 |
| A_6 | 0.3629 | 0.4565 | 0.4429 | 6 |
| A_7 | 0.3690 | 0.3461 | 0.5161 | 3 |
| A_8 | 0.3115 | 0.3749 | 0.4539 | 5 |

Zalety i wady metody TOPSIS

Zalety:

- Intuicyjna i łatwa do zrozumienia oraz implementacji.
- Uwzględnia zarówno rozwiązanie idealne, jak i anty-idealne.
- Może być stosowana do różnych typów kryteriów (ilościowe i jakościowe po normalizacji).
- Wyniki są uporządkowane w postaci wskaźnika bliskości, co ułatwia ranking alternatyw.

Wady:

- Wrażliwość na wybór metody normalizacji i wag kryteriów.
- W przypadku bardzo podobnych alternatyw różnice w odległościach mogą być minimalne, utrudniając ranking.
- Wynik nie uwzględnia niepewności lub subiektywności oceny decydenta poza wagami.

Problem odwrócenia rang (Rank Reversal) 1

Odwrócenie rang

Rank reversal to zjawisko, w którym wprowadzenie nowej alternatywy lub usunięcie istniejącej powoduje zmianę kolejności (rang) pozostałych alternatyw w rankingu, mimo że ich własne oceny nie uległy zmianie.

Przyczyny

- Niektóre metody są wrażliwe na skalę i relatywne odległości między alternatywami (TOPSIS).
- Wprowadzenie alternatywy do zbioru może przesunąć wskaźnik bliskości PIS/NIS innych alternatyw.
- W metodach opartych na agregacji normalizowanych wartości wprowadzenie dodatkowego elementu zmienia zbiór normalizacji.

Problem odwrócenia rang (Rank Reversal) 2

Skutki

- Ranking może ulec zmianie w sposób nieintuicyjny dla decydenta.
- Może prowadzić do błędnych decyzji, jeśli nowe alternatywy wprowadzane są dynamicznie.

Przykład

- Alternatywy A_1, A_2 mają ranking: $A_1 > A_2$
- Wprowadzenie nowej, gorszej, alternatywy A_3 zmienia ranking na: $A_2 > A_1 > A_3$
- Pomimo że alternatywy A_1 i A_2 nie zmieniły się, ich ranga uległa odwróceniu.

Podsumowanie

- ISWD (Inteligentne Systemy Wspomagania Decyzji) łączą podejścia z zakresu OR, MCDA, AI i wiedzę ekspercką, aby wspierać procesy decyzyjne.
- MCDA umożliwia analizę decyzji wielokryterialnych, porównywanie alternatyw i uwzględnianie wag oraz preferencji decydenta.
- TOPSIS to popularna i praktyczna metoda rankingowa, uwzględniająca zarówno rozwiązanie idealne, jak i anty-idealne. Jak każda metoda, ma swoje zalety i wady.

Źródła

- https://en.wikipedia.org/wiki/Operations_research
- <https://www.informs.org/Resource-Center/INFORMS-Student-Union/Consider-an-Analytics-OR-Career>
- <https://www.ibm.com/products/cognos-analytics/financial>
- <https://github.com/norvig/paip-lisp/blob/main/docs/chapter16.md>
- <https://make-decision.it/#/about>
- <https://diviz.org/>

Dziękuję za uwagę!